

Autonome Schraubensortierung mittels Unsupervised Learning

Dominic Dötterer, Pascal Graf und Nicolaj C. Stache
Automotive Systems Engineering, Heilbronn University of Applied Sciences

Projektübersicht

Motivation:

- Demonstrator zeigt KI im Bereich der industriellen Fertigung, die ohne menschliches Expertenwissen lernt, Objekte auf einem Fließband in unterschiedliche Kategorien einzuordnen und zu sortieren.
- Einsatzmöglichkeiten im Bereich der Anomalie-Detektion von Bauteilen, der Sortierung von gemischtem Schüttgut oder der Mülltrennung.

Ansatz / Ziele:

- Schrauben (oder andere Kleinteile) werden durch Voreinzeller voneinander getrennt und von Fließband transportiert.
- Beim ersten Durchlauf nimmt die Kamera Objekte einzeln auf, wichtige Features werden extrahiert und gespeichert.
- Nach Clustering der gesammelten Daten werden Objekte beim zweiten Durchlauf durch Roboterarm automatisch einsortiert.




Abbildung 1: 3D Modell der Sortieranlage bestehend aus Voreinzeller, Fließband, Kamera + Beleuchtung, Roboterarm, Sortierkästen und Eingriffschutz.

Programmablauf

- 1. Durchlauf: Features einzelner Objekte werden aus Bildern extrahiert. Sowohl klassische Bildverarbeitungs-Features wie mittlere Farbwerte, Objektgröße und -proportionen als auch automatisch über ein tiefes neuronales Netzwerk gewonnene Features.
- Zwischen den Durchläufen: Features werden mittels Hauptkomponentenanalyse (PCA) [1] auf niedrigdimensionalen Raum reduziert und in mehrere Gruppen geclustert.
- 2. Durchlauf: Objekt-Features werden erneut extrahiert und sowohl bekannte als auch unbekannte Objekte den jeweiligen Clustern zugeordnet und einsortiert.

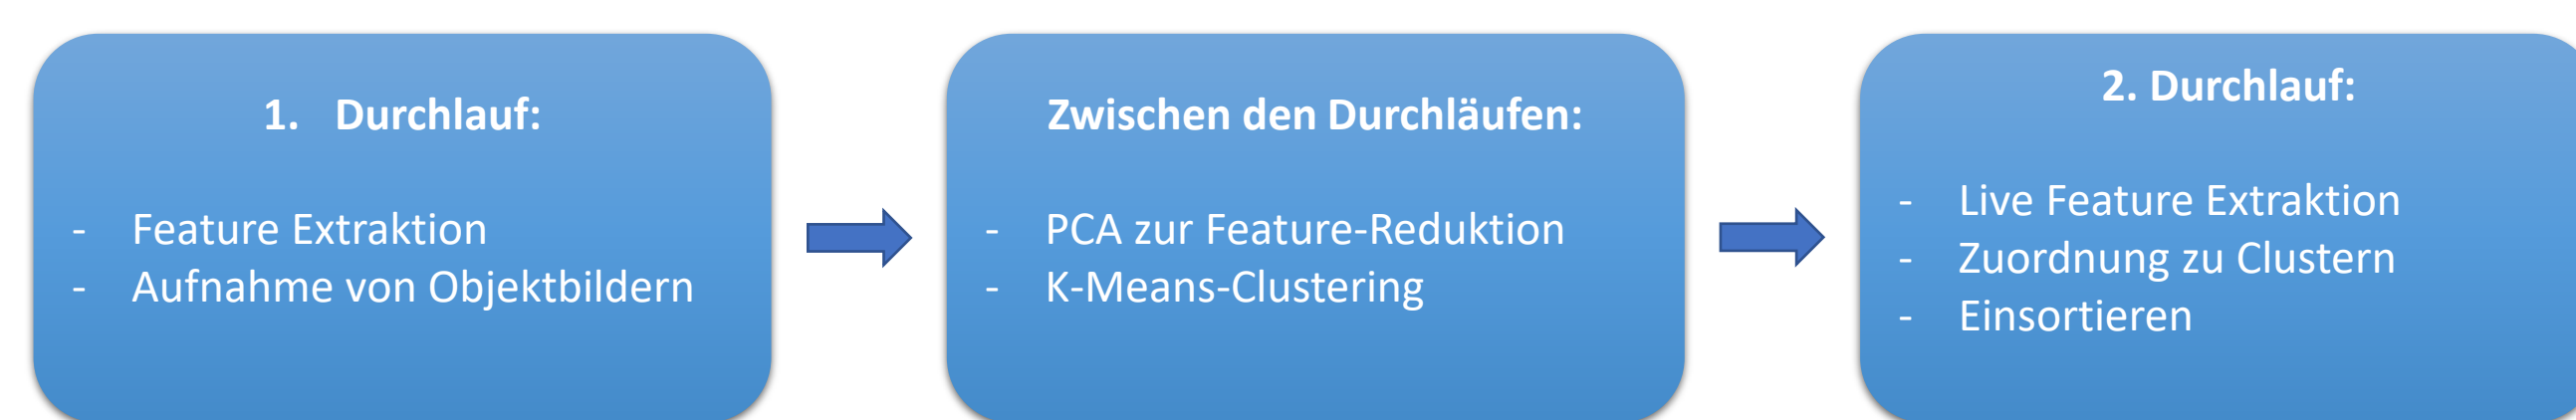


Abbildung 2: Programmablauf des autonomen Sortiervorgangs von Feature-Extraktion und Datensammlung bis zu Clustering und Einsortieren.

Feature Extraktion

Klassische Bildverarbeitung:

- Bild-Features können aus den Aufnahmen einzelner Objekte direkt gewonnen werden. Dazu werden u.a. Objektkonturen und Bounding-Boxen betrachtet.
- Folgende Features werden extrahiert: Mittlere Objektfarbe, Objekt-Fläche in Pixel, Seitenverhältnis Länge zu Breite, Hu-Momente [2], Solidität, Ausdehnung und Objektlänge in Pixel.
- Ein trainiertes tiefes neuronales Netzwerk mit Autoencoder-Architektur extrahiert implizit relevante Bildfeatures.




Abbildung 3: Beispielhafte Feature-Extraktion mittels klassischer Bildverarbeitung. Kameraaufnahme mit Bounding Boxen erkannter Objekte im relevanten Bildbereich (links), Kantenbild und erkannte Objektkontur (mittig), ermittelte Bildfeatures (rechts).

Tiefe neuronale Netzwerke:

- Ein trainiertes *Convolutional Neural Network* (CNN) mit Autoencoder-Architektur extrahiert implizit relevante Bildfeatures.
- Das Netzwerk wurde dabei zunächst darauf trainiert, Bilder in einen latenten Raum zu komprimieren und dann möglichst exakt zu rekonstruieren




Abbildung 4: Schematische Darstellung eines Convolutional Autoencoders. Der Encoder komprimiert das Input-Bild in den latenten Raum und extrahiert dabei die relevantesten Features. Der Decoder versucht, das Input Bild anhand der latenten Repräsentation wiederherzustellen.

Clustering




Abbildung 5: Features im PCA reduzierten 3D-Raum mit acht ermittelten Clustern.

Hauptkomponentenanalyse:

- Im hochdimensionalen Raum können Features nicht visualisiert werden.
- Die Principal Component Analysis (PCA) reduziert einen Datensatz auf zwei bis drei Merkmale, die das größte Entscheidungspotential aufweisen.

K-Means-Clustering:

- Beim K-Means-Clustering [3] wird versucht, eine Sammlung von Datenpunkten in k vorgegebene Gruppen einzuteilen, sodass die Varianz innerhalb dieser Gruppen möglichst klein ist.
- Das Verfahren wird mit unterschiedlichem k gestartet, um die optimale Cluster-Anzahl zu bestimmen.
- Neue Datenpunkte werden bestehenden Clustern zugeordnet.

Ergebnisanalyse

- Schrauben werden nach für Menschen plausiblen Kriterien in unterschiedliche Cluster eingeteilt.
- Fokus des autonomen Systems bei der Unterscheidung scheint auf Größe, Form und Farbe von Objekten zu liegen.
- Unbekannte Schraubenarten werden ebenfalls sinnvoll eingeordnet.




Abbildung 6: Drei beispielhafte Cluster unterschiedlicher Schraubensorten, die anhand klassischer und Autoencoder Features autonom gebildet wurden.

Quellen

[1] Jolliffe, I.T.. "Principal Component Analysis." Springer Verlag, 1986.

[2] Hu, Ming-Kuei. "Visual pattern recognition by moment invariants." *Information Theory, IRE Transactions*, 1962.

[3] Hartigan, J. A. and Wong, M. A.. "A k-means clustering algorithm." *JSTOR: Applied Statistics* 28, 1979.